

约束渐进式置信度引导世界模型 (CPCG-WM) 研究计划书

面向通信系统的置信度 World Model 训练框架

Cogito

2026 年 7 月 3 日

摘要

本计划书提出一种面向通信系统的**约束渐进式置信度引导世界模型** (Constraint-Progressive Confidence-Guided World Model, CPCG-WM)。该方向的核心目标是训练世界动作模型直接预测通信系统未来观测序列分布。经典通信模型在本框架中作为带置信度的训练教师，在高置信样本上通过经典一致性损失约束神经世界模型，在低置信样本上平滑减弱其影响，由真实观测数据主导模型学习低约束条件下新增自由度。该框架将通信领域的高约束模型、可控仿真环境和现代具身智能 World Model 训练范式结合起来，形成从高约束规律塑形到低约束观测动态学习的训练路线。

本文档围绕研究目标、数据生成、观测序列设计、经典教师构造、置信度估计、RSSM 风格世界模型架构、训练目标、候选稳定化策略、实验验证和阶段计划进行详细说明。计划中的可选部分均以“候选实现”形式记录，便于后续根据 ns-3、Komondor/Kom8ndor 等仿真平台实际可导出的数据字段进行工程落地。

关键词：通信世界模型；约束渐进；置信度引导训练；RSSM；ns-3；Kom8ndor；WiFi-8

目录

1	研究定位与总体目标	4
1.1	研究问题	4
1.2	核心思想	4
1.3	研究边界	4
2	方法总览	5
2.1	整体框架	5
2.2	方法原则	5
3	数据来源与数据集构建	5
3.1	仿真平台	5
3.2	数据生成原则 (仅供参考)	6
3.3	Episode 数据结构参考	6
3.4	观测 o_t 设计候选	7
4	经典模型教师与置信度估计	8
4.1	经典模型教师	8
4.2	置信度定义	8
4.3	置信度估计候选	8
4.4	分开训练策略	9
5	World Model 架构	9
5.1	推荐主干: RSSM 风格时序世界模型	9
5.2	模块说明	9
5.3	架构候选实现	10
6	训练目标	11
6.1	World Model 主损失	11
6.2	经典一致性损失	11
6.3	$\lambda(c)$ 候选映射	11
6.4	RSSM 潜变量一致性损失	11
6.5	总训练目标	12
7	训练流程与候选技巧	12
7.1	基础训练流程	12
7.2	训练稳定化候选	12
7.3	约束渐进训练候选流程	15
7.4	学生限制候选	17

目录	3
7.5 训练稳定化候选	21
7.6 约束渐进训练候选流程	21
7.7 学生限制候选	21
8 实验设计与验证指标	22
8.1 核心对照组	22
8.2 WM 预测指标, 仅供参考	22
8.3 约束渐进泛化验证	23
8.4 置信度模块评估	23
9 风险与应对	23
10 预期贡献	24
11 总结	24

1 研究定位与总体目标

1.1 研究问题

通信系统具有明显的双重特征：一方面，在高约束条件下，传统通信模型、排队近似、协议规则和信道模型能够给出稳定、可解释的预测；另一方面，在真实或低约束场景中，流量非平稳、隐藏干扰、部分观测缺失、协议状态复杂、设备异构和环境动态变化会引入额外自由度，使经典模型的绝对预测结果不再可靠。

本研究排除了将经典模型直接嵌入神经网络前向结构与输出残差形式。研究重点是：

如何利用经典模型在高置信区域中的可靠规律，对神经世界模型的训练过程进行软约束，使其在高约束世界中获得规律塑形，并在低约束世界中通过真实观测数据学习新增自由度。

1.2 核心思想

设通信系统在时间 t 的观测为 o_t ，动作为 a_t ，历史观测窗口为 $o_{\leq t}$ 。神经世界模型直接学习未来观测分布：

$$q_\theta(o_{t+\tau} \mid o_{\leq t}, a_t), \quad \tau \in \mathcal{H}, \quad (1)$$

其中 $\mathcal{H}$ 为多步预测窗口，例如 $\{1, 2, 4, 8\}$ 。经典模型给出其可覆盖观测子空间上的软教师分布：

$$p_c(o_{t+\tau}^{\mathcal{S}_c} \mid o_{\leq t}, a_t), \quad (2)$$

其中 $\mathcal{S}_c$ 表示经典模型能够预测或近似约束的观测字段集合。置信度模块输出经典模型在当前样本上的可信程度：

$$c = Q_\eta(o_{\leq t}, a_t, p_c, \text{context}) \in [0, 1]. \quad (3)$$

训练时，经典一致性损失由 $\lambda(c)$ 加权：

$$\mathcal{L} = \mathcal{L}_{\text{WM}} + \lambda(c)\mathcal{L}_{\text{classic}} + \alpha\mathcal{L}_{\text{latent}}. \quad (4)$$

高置信时， $\lambda(c)$ 较大，神经 WM 被经典模型可靠区域塑形；低置信时， $\lambda(c)$ 接近零，神经 WM 主要由真实观测监督学习低约束动态。

1.3 研究边界

本文计划聚焦 WM 训练本身，暂不展开基于 WM 的规划与控制策略。后续可在训练完成的世界模型上接入候选动作评估、MPC 或风险感知决策模块。

2 方法总览

2.1 整体框架




图 1: CPCG-WM 的总体训练框架。神经 WM 直接预测未来观测分布；经典模型只作为训练教师，通过置信度加权的经典一致性损失影响神经模型。

2.2 方法原则

1. **经典模型不进入前向残差。**神经模型直接输出未来观测分布；经典模型仅在训练损失中提供软约束。
2. **置信度控制学习空间。**高置信样本中经典一致性约束强，低置信样本中约束弱或近似关闭。
3. **约束渐进体现在训练分布与损失权重。**高约束世界用于规律塑形，低约束世界用于新增自由度学习。
4. **架构可随数据字段调整。**输入 token、RSSM 状态维度、输出字段、经典教师覆盖子空间等均依据仿真数据实际可导出字段确定。

3 数据来源与数据集构建

3.1 仿真平台

本研究计划使用 ns-3 与 Komondor/Kom8ndor 作为主要数据来源。ns-3 是研究和教学中广泛使用的离散事件网络仿真平台，可用于构造通信协议、拓扑、流量与链路状态等系统级网络场景。Kom8ndor 是面向 IEEE 802.11bn/Wi-Fi 8 的仿真工具，扩展了

Komondor 平台, 支持多 AP 协调相关功能, 并提供面向 AI 协议研究的 machine learning wrapper, 适合生成动作-未来观测轨迹数据 [1]。802.11bn/Wi-Fi 8 的 UHR 目标强调可靠性、尾延迟和 MPDU loss 等指标, 且多 AP 协调 (MAPC) 是关键方向之一 [2]。

3.2 数据生成原则 (仅供参考)

数据集不应仅按 AP 数量或拓扑规模划分高低约束, 而应按生成世界转移所需自由度设计约束层级。参考维度如下:

表 1: 约束渐进数据族的参考维度

约束维度	高约束参考设置	低约束参考设置
可观测性	关键队列、链路、负载、动作结果较完整可观测	部分队列、链路、干扰或协议状态缺失
流量稳定性	平稳或弱突发流量	非平稳、重尾、突发到达或业务切换
干扰建模	干扰源可分离、可近似估计	隐藏干扰、外部 BSS、动态干扰源
信道动态	慢变信道、参数扰动有限	快变信道、遮挡、移动性、测量噪声增强
协议复杂度	协议状态近似可见或简化	隐藏退避、重传、MLO/MAPC 交互复杂化
设备异构性	设备行为同质、参数稳定	设备能力、负载、协议实现或功率策略异构
动作后果稳定性	同一动作在相近状态下结果分布窄	同一动作受隐藏因素影响, 结果分布更宽

3.3 Episode 数据结构参考

最终字段需依据仿真器可导出内容确定。建议每条 episode 记录为连续时序:

$$\mathcal{D}_i = \{(o_t, a_t, o_{t+1}, \text{meta}_t)\}_{t=1}^{T_i}. \quad (5)$$

其中 meta_t 仅用于数据分析、划分、置信度标签构造和评估, 不一定作为神经 WM 输入。

表 2: 数据字段参考结构

字段	说明
episode_id	场景轨迹编号。
time_step	离散时间索引, 时间粒度由仿真日志决定。
o_t	当前观测 token 集合, 可包括事件、状态摘要、协议/链路测量、KPI token。
a_t	当前动作, 可为调度、信道选择、接入控制、MAPC 方式、功率/阈值配置等。
$o_{t+\tau}$	多步未来观测监督, $\tau \in \mathcal{H}$ 。
$o_{t+\tau}^{S_c}$	经典模型可覆盖的未来观测子字段。
p_c	经典模型给出的子观测软教师分布或确定性预测转化后的分布。
c^*	训练置信度模块使用的教师可靠性标签, 由经典误差、规则或一致性估计获得。
family_id	生成机制族编号, 仅用于分层采样、留一族测试或统计分析。
constraint_config	约束自由度配置, 如观测缺失率、隐藏干扰强度、流量突发参数等。

3.4 观测 o_t 设计候选

观测设计需要与实际可获取数据一致。候选结构如下:

1. **事件级 token:** packet arrival、transmission attempt、ACK/failure、backoff event、CCA busy/idle、queue update、channel measurement、action applied。
2. **状态摘要 token:** queue length、airtime usage、retry rate、loss rate、delay histogram、traffic load、channel/link quality、contention level。
3. **KPI token:** throughput、p95 delay、packet/MPDU loss、fairness、risk/violation flag。KPI 作为观测字段之一, 不单独构成模型目标。
4. **协议与配置 token:** 802.11ax/be/bn 相关配置、MLO/MAPC 模式、信道宽度、功率、阈值、调度模式等。

4 经典模型教师与置信度估计

4.1 经典模型教师

经典模型教师 C 的作用是给出其覆盖子空间 $\mathcal{S}_c$ 上的软教师分布：

$$p_c(o_{t+\tau}^{\mathcal{S}_c} \mid o_{\leq t}, a_t). \quad (6)$$

若经典模型只能给出确定性预测 $\hat{o}^c$ ，则可按字段类型转换为软分布。例如，对于离散化观测字段 k ：

$$p_c(k) = \frac{\exp(-d(k, \hat{o}^c)^2/T_c)}{\sum_{k'} \exp(-d(k', \hat{o}^c)^2/T_c)}, \quad (7)$$

其中 T_c 控制经典教师分布的平滑程度。

4.2 置信度定义

置信度 $c \in [0, 1]$ 表示经典模型在当前样本上的可靠程度。训练时可利用真实未来观测构造可靠性标签：

$$e_c = \mathcal{D}(p_c, o_{t+\tau}^{\mathcal{S}_c, \text{true}}), \quad (8)$$

$$c^* = \exp(-e_c/T_e), \quad (9)$$

其中 $\mathcal{D}$ 可选交叉熵、负对数似然或分布距离， T_e 为温度系数。置信度模块训练目标为：

$$\mathcal{L}_{\text{conf}} = \|Q_\eta(o_{\leq t}, a_t, p_c, \text{aux}) - c^*\|_2^2, \quad (10)$$

或采用可靠/不可靠二分类形式。

4.3 置信度估计候选

表 3: 置信度估计方式候选

候选方式	说明	角色
规则式假设满足度	根据经典模型适用假设是否满足构造置信度，如观测完整性、流量稳定性、动作覆盖范围。	无需训练
多经典模型一致性	使用多个经典模型、参数版本或简化假设版本；输出方差越小，置信度越高。	稳健估计
局部敏感性	经典模型对输入扰动越敏感，说明当前样本越不稳定，置信度越低。	稳定性度量

小型置信度网络	训练时使用 y_{true} 或 o^{true} 校准, 推理时预测经典模型可靠性。	主候选
混合置信度	规则、一致性、敏感性与校准网络加权融合。	后续增强

4.4 分开训练策略

建议置信度模块与 WM 分开训练:

1. 固定经典模型, 在训练集上生成 p_c 。
2. 根据真实未来观测计算经典模型误差 e_c 与置信度标签 c^* 。
3. 训练 Q_η , 并在验证集校准其可靠性。
4. 固定或半固定 Q_η , 使用 $\lambda(c)$ 训练神经 WM。

分开训练可避免置信度模块与 WM 之间出现相互逃避约束的 shortcut。

5 World Model 架构

5.1 推荐主干: RSSM 风格时序世界模型

暂时建议以 RSSM 风格 latent dynamics 作为主干。RSSM 的优势是同时建模确定性历史状态与随机潜变量, 适合多步观测预测和不确定性环境。现代 World Model 工作已经证明, latent dynamics、多步 imagined future、decoder-free 或弱重建训练均可显著提升世界模型的泛化与稳定性 [3, 4, 5]。

5.2 模块说明

1. **Observation Tokenizer:** 将仿真日志中的事件、状态摘要、协议配置和 KPI 字段统一转换为 token 序列或字段分布。
2. **History Encoder:** 编码 $o_{\leq t}$ 与过去动作, 形成后验潜变量。
3. **RSSM Latent State:** 维护确定性时序状态 h_t 与随机潜变量 z_t 。
4. **Action-conditioned Dynamics:** 给定 z_t, h_t, a_t , 预测未来潜变量分布。
5. **Observation Distribution Heads:** 对未来观测 token 或字段分布建模, 输出 $q_\theta(o_{t+\tau})$ 。
6. **Classic Teacher Branch:** 训练时使用, 提供 p_c 、 c 与经典一致性损失。




图 2: RSSM 风格 CPCG-WM 架构参考。神经 WM 预测完整未来观测分布；经典模型只在可覆盖观测子空间提供置信度加权 KL 约束。

5.3 架构候选实现

表 4: WM 架构候选实现

功能	候选实现	本人建议
时序主干	RSSM、GRU-RSSM、Transformer-RSSM、长序列 情况下可考虑 SSM/Mamba 类主干。	RSSM
Tokenizer	字段 token、事件 token、关系 token、混合 token。	看情况
输出建模	离散 bin 分布、连续分布参数、混合密度、二值 风险分布。	分布输出

多步预测	直接预测 $\tau = 1, 2, 4, 8$, 或 RSSM rollout 后预测。直接多步 + rollout 对照
经典教师作用空间	经典模型可覆盖的观测子字段 $\mathcal{S}_c$ 。子空间 KL

6 训练目标

6.1 World Model 主损失

对未来观测分布进行负对数似然训练：

$$\mathcal{L}_{\text{WM}} = - \sum_{\tau \in \mathcal{H}} \sum_{j \in \mathcal{S}_{obs}} w_j \log q_{\theta} \left(\sigma_{t+\tau}^{j, true} \mid o_{\leq t}, a_t \right), \quad (11)$$

其中 $\mathcal{S}_{obs}$ 为观测字段集合， w_j 为字段权重。连续字段可离散化为分布，也可用参数化概率分布计算 NLL。

6.2 经典一致性损失

经典模型只在其覆盖字段 $\mathcal{S}_c$ 上约束神经 WM：

$$\mathcal{L}_{\text{classic}} = \sum_{\tau \in \mathcal{H}} \sum_{j \in \mathcal{S}_c} D_{\text{KL}} \left(p_c(\sigma_{t+\tau}^j) \parallel q_{\theta}(\sigma_{t+\tau}^j) \right). \quad (12)$$

最终加权形式为：

$$\mathcal{L}_{\text{CG}} = \lambda(c) \mathcal{L}_{\text{classic}}. \quad (13)$$

6.3 $\lambda(c)$ 候选映射

$\lambda(c)$ 是本方法中控制经典教师影响力的关键函数，候选形式包括：

$$\lambda(c) = \lambda_{\max} c^{\gamma}, \quad (14)$$

$$\lambda(c) = \lambda_{\max} \cdot \sigma(k(c - \tau_c)), \quad (15)$$

$$\lambda(c) = \begin{cases} 0, & c < c_0, \\ \lambda_{\max} \left(\frac{c - c_0}{1 - c_0} \right)^{\gamma}, & c \geq c_0. \end{cases} \quad (16)$$

可通过验证集选择 $\lambda_{\max}$ 、 γ 、 k 与阈值参数。

6.4 RSSM 潜变量一致性损失

若采用 RSSM，可加入后验与先验之间的 latent consistency 或 KL balancing：

$$\mathcal{L}_{\text{latent}} = \sum_t D_{\text{KL}} \left(q_{\theta}(z_t \mid o_{\leq t}) \parallel p_{\theta}(z_t \mid h_t) \right), \quad (17)$$

并采用 stop-gradient、KL balancing、free bits 等稳定技巧作为候选实现。该项服务于 RSSM 稳定训练，不改变 CPCG-WM 的核心定义。

6.5 总训练目标

在 WM 训练阶段：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{WM}} + \beta \mathcal{L}_{\text{latent}} + \lambda(c) \mathcal{L}_{\text{classic}}. \quad (18)$$

置信度模块 Q_η 建议先独立训练，其损失不与 WM 主损失端到端耦合。

7 训练流程与候选技巧

7.1 基础训练流程




图 3: 基础训练流程。置信度模块先独立训练，再用于调制经典一致性损失。

7.2 训练稳定化候选

CPCG-WM 的训练同时包含观测预测损失、RSSM 潜变量一致性损失以及置信度加权经典一致性损失。不同损失项的尺度、收敛速度和作用区域不同，因此训练稳定化策略需要围绕三个目标展开：第一，保证 RSSM 风格世界模型能够稳定学习时序观测动态；第二，防止经典一致性约束在训练早期过强或过弱；第三，避免低约束适配阶段破

坏高置信区域中已学习到的稳定规律。以下策略均作为候选实现保留，可根据数据规模、观测字段质量与验证集表现选择。

1. 损失尺度归一化与字段权重平衡 观测 o_t 可能由多类字段组成，例如事件字段、状态摘要字段、协议配置字段和 KPI 字段。不同字段的取值范围、噪声水平和预测难度差异较大。若直接将所有字段的 NLL 或 CE 相加，容易导致某些高方差字段主导训练。建议对观测字段损失进行归一化或分组加权：

$$\mathcal{L}_{WM} = \sum_{\tau \in \mathcal{H}} \sum_{j \in \mathcal{S}_{obs}} w_j \mathcal{L}_{obs}^j(q_\theta(o_{t+\tau}^j), o_{t+\tau}^{j,true}), \quad (19)$$

其中 w_j 可根据字段重要性、数值尺度、噪声水平或验证集误差进行设置。第一版可采用分组等权策略，即事件类、状态摘要类、协议类和 KPI 类各自归一化后再求和，避免模型只优化少数易预测或高权重字段。

2. $\lambda(c)$ warm-up 与约束裁剪 经典一致性项的作用强度由 $\lambda(c)$ 控制。即使置信度估计较准确，训练早期神经 WM 尚未形成稳定时序表征，如果直接施加强经典 KL，可能导致模型过早贴近经典教师分布而影响观测动态学习。因此建议使用训练步数相关的 warm-up：

$$\lambda_t(c) = s(t)\lambda(c), \quad (20)$$

其中 $s(t)$ 从 0 平滑增长到 1。候选形式包括线性 warm-up、余弦 warm-up 或分阶段 warm-up。若训练中发现经典 KL 梯度过大，还可对经典一致性项进行上限裁剪：

$$\mathcal{L}_{CG} = \min(\lambda(c)\mathcal{L}_{classic}, L_{\max}^{CG}). \quad (21)$$

该策略用于避免少量高置信但经典误差较大的样本主导训练。裁剪阈值 $L_{\max}^{CG}$ 作为候选超参数，不进入方法核心定义。

3. 置信度边界与温度平滑 置信度模块 Q_η 的输出可能在训练早期存在校准误差。为避免极端置信度导致训练不稳定，可对 c 进行边界截断或温度平滑：

$$\tilde{c} = \text{clip}(c, c_{\min}, c_{\max}), \quad (22)$$

或

$$\tilde{c} = \sigma\left(\frac{\text{logit}(c)}{T_c}\right). \quad (23)$$

其中 $c_{\min}$ 防止经典约束完全消失， $c_{\max}$ 防止经典教师在单个样本上形成过强硬约束。若后续实验表明低置信样本应完全不参考经典模型，则可将 $c_{\min}$ 设为 0；否则可保留一个较小值作为弱正则。

4. RSSM 潜变量稳定技巧 若采用 RSSM 风格主干，需要防止 posterior collapse、先验分布不稳定、多步 rollout 发散等问题。候选稳定技巧包括：

1. **KL balancing**: 区分 prior 与 posterior 两侧的梯度权重，避免后验编码器或先验转移模型单侧主导训练。
2. **Free bits**: 对每个 latent 维度设置最低 KL 使用量，防止潜变量被模型忽略。
3. **Stop-gradient**: 在先验-后验一致性项中对部分路径停止梯度，稳定 latent dynamics。
4. **梯度裁剪**: 对 RSSM 主干和观测预测头进行 global norm clipping，避免长序列训练中梯度爆炸。
5. **短到长 horizon**: 先训练短步预测，再逐渐增加多步 rollout 的权重，降低早期多步误差累积。

这些技巧服务于 RSSM 稳定训练，不改变 CPCG-WM 的核心思想。

5. Teacher dropout 为防止神经 WM 对经典教师产生过度依赖，可在部分 batch 中关闭经典一致性项，仅保留真实观测监督：

$$\mathcal{L} = \mathcal{L}_{WM} + \beta \mathcal{L}_{latent} + m_{teacher} \lambda(c) \mathcal{L}_{classic}, \quad (24)$$

其中 $m_{teacher} \sim \text{Bernoulli}(1 - p_{drop})$ 。Teacher dropout 的作用不是削弱经典模型价值，而是迫使 WM 在没有经典教师约束时仍能依靠自身 latent dynamics 预测未来观测。该策略尤其适合低约束适配阶段或经典覆盖子空间较窄的场景。 p_{drop} 不宜过大，否则经典一致性塑形作用会被削弱。

6. 置信度分层采样 由于高置信样本、中置信样本和低置信样本在训练中承担不同作用，建议按照置信度分层构造 batch，而不是完全随机采样。设样本集合按置信度划分为：

$$\mathcal{D}_{high}, \quad \mathcal{D}_{mid}, \quad \mathcal{D}_{low}. \quad (25)$$

训练过程中可控制三类样本比例，使模型先在高置信区域获得规律塑形，再逐步接触低约束自由度。该策略与第 7.3 节中的约束渐进流程配合使用。

7. 高置信样本回放 低约束适配阶段中，模型可能逐渐偏离高置信区域中已学到的稳定规律。为缓解遗忘，建议在训练低置信样本时持续混入少量高置信 replay batch：

$$\mathcal{B} = \mathcal{B}_{low} \cup \mathcal{B}_{mid} \cup \mathcal{B}_{replay}^{high}. \quad (26)$$

高置信 replay 的比例可作为候选超参数，建议从 10%-25% 区间尝试。若 replay 比例过低，可能无法防止遗忘；若比例过高，则可能限制低约束适配。

8. 阶段切换时的优化器 reset 当训练从高置信塑形阶段切换到混合约束阶段，或从混合约束阶段切换到低约束适配阶段时，loss 结构和样本分布会发生变化。此时可重置优化器状态，尤其是 Adam 类优化器的一阶和二阶动量：

$$\theta \leftarrow \theta, \quad \text{state}_{\text{optimizer}} \leftarrow 0. \quad (27)$$

该操作保留模型参数，但清空旧阶段的优化惯性，通常比完全重置模型更稳。若输出分布头在低约束阶段出现明显校准偏移，可将 prediction head reset 作为候选实验；不建议重置 encoder 或 RSSM 主干，因为这会破坏高置信阶段形成的时序规律表征。

表 5: 训练稳定化候选策略

目标	候选策略	使用阶段
平衡观测字段损失	字段分组归一化、字段权重 w_j 、连续/离散字段分别建模	全阶段
防止经典约束过强	$\lambda(c)$ warm-up、经典 KL 裁剪、置信度边界截断	训练早期与高置信阶段
稳定 RSSM 训练	KL balancing、free bits、stop-gradient、梯度裁剪、短到长 horizon	全阶段
防止 teacher 依赖	Teacher dropout, 部分 batch 关闭经典一致性项	混合阶段与低约束阶段
防止高置信规律遗忘	高置信 replay、置信度分层采样	低约束适配阶段
适应阶段切换	Reset optimizer; 必要时 reset prediction head	阶段切换时

7.3 约束渐进训练候选流程

CPCG-WM 的约束渐进不应仅理解为数据复杂度增加，而应体现为训练中经典教师约束强度、样本置信度分布、观测动态自由度和模型适配目标的逐步变化。高置信样本用于塑造 WM 对稳定通信观测动态的基础认知；中低置信样本用于引入新增自由度；低置信真实观测用于训练模型在经典教师不可靠区域中的预测能力。完整流程可采用以下候选阶段。

阶段 0: 经典教师与置信度模块准备 在训练神经 WM 之前，先固定经典模型并生成其可覆盖观测子空间上的教师分布：

$$p_c(o_{t+\tau}^{\mathcal{S}_c} | o_{\leq t}, a_t). \quad (28)$$

随后利用真实未来观测构造经典模型误差 e_c 和置信度标签 c^* ，独立训练置信度模块 Q_η 。该阶段不训练 WM，目的是得到稳定的 c 与 $\lambda(c)$ 调制信号。若置信度模块在验证集上无法区分经典模型可靠与不可靠样本，则不应进入主训练阶段，而应优先调整置信度来源，例如增加多经典模型一致性、局部敏感性或规则式假设满足度特征。

阶段 1：高置信塑形阶段 该阶段主要采样高置信样本 $\mathcal{D}_{high}$ ，训练目标为：

$$\mathcal{L} = \mathcal{L}_{WM} + \beta \mathcal{L}_{latent} + \lambda(c) \mathcal{L}_{classic}. \quad (29)$$

由于 c 较高，经典一致性约束较强。该阶段的目标不是让模型记住经典模型输出，而是让 RSSM latent dynamics 在高置信通信世界中学习稳定的观测转移规律。建议此阶段使用较短预测 horizon，例如 $\tau = 1, 2$ ，并采用较低 teacher dropout。若训练稳定，可逐渐加入更长 horizon。

候选采样比例为：

$$\mathcal{D}_{high} : 70\% - 90\%, \quad \mathcal{D}_{mid} : 10\% - 30\%, \quad \mathcal{D}_{low} : 0\% - 10\%. \quad (30)$$

该比例仅作为初始参考，具体应根据数据量和置信度分布调整。

阶段 2：混合约束阶段 该阶段逐步提高中置信与低置信样本比例，使模型从高置信规律区域过渡到更复杂的观测动态。训练仍使用置信度加权经典一致性损失，但 $\lambda(c)$ 会自动降低低置信样本中的经典约束。该阶段可引入 teacher dropout、字段 masking 和多步预测，以防止模型过度依赖高置信教师。

候选采样比例为：

$$\mathcal{D}_{high} : 35\% - 55\%, \quad \mathcal{D}_{mid} : 30\% - 45\%, \quad \mathcal{D}_{low} : 10\% - 30\%. \quad (31)$$

该阶段应重点监控三类指标：第一，真实观测 NLL 是否下降；第二，高置信样本上的经典一致性是否保持；第三，中低置信样本上的预测误差是否开始改善。若中低置信样本误差不降，说明模型没有有效学习新增自由度；若高置信误差显著变差，说明模型出现高置信规律遗忘。

阶段 3：低约束适配阶段 该阶段加大低置信或低约束样本比例，训练主要由真实观测监督主导：

$$\mathcal{L} \approx \mathcal{L}_{WM} + \beta \mathcal{L}_{latent} + \lambda(c) \mathcal{L}_{classic}, \quad \lambda(c) \approx 0 \text{ for } c \text{ low}. \quad (32)$$

由于低置信样本中经典模型约束较弱，模型需要依靠前两个阶段形成的时序表征和真实观测数据学习新增自由度。该阶段建议保留 10%-25% 的高置信 replay，以避免模型完全偏离高置信规律区域。

候选采样比例为：

$$\mathcal{D}_{high} : 10\% - 25\%, \quad \mathcal{D}_{mid} : 20\% - 35\%, \quad \mathcal{D}_{low} : 45\% - 70\%. \quad (33)$$

若切换到该阶段后训练震荡明显，可 reset optimizer；若仅输出分布校准出现问题，可尝试 reset prediction head，但保留 tokenizer、encoder 与 RSSM latent dynamics。

阶段 4：循环训练与回放 refinement 若低约束适配后高置信样本表现下降，或 leave-one-family-out 泛化不稳定，可采用循环训练。一次循环可包含：

1. 高置信 replay：短时间回到高置信样本，恢复稳定观测动态；
2. 混合约束训练：重新混入中低置信样本，保持过渡区域性能；
3. 低约束适配：继续强化低约束自由度学习；
4. 验证集选择：以多步观测 NLL、置信度分层误差和 leave-one-family-out 结果选择 checkpoint。

循环训练的重点不是反复重训模型，而是通过不同置信度区域的交替训练，避免模型只适应某一个分布区域。每轮循环开始时可 reset optimizer，但不建议 reset 整个模型。若多轮循环后低约束性能提升但高置信性能持续退化，应提高高置信 replay 比例或降低低置信阶段学习率。

阶段 5：少量低约束适配验证 为了验证高置信塑形是否真正提升了低约束学习效率，可设计少量低约束适配实验。做法是在固定少量低约束训练样本的条件下，比较以下模型：

1. 未使用经典一致性训练的纯神经 WM；
2. 使用高置信塑形但不使用低约束适配的 WM；
3. 使用高置信塑形并进行少量低约束适配的 CPCG-WM；
4. 打乱置信度后训练的 CPCG-WM。

若 CPCG-WM 在少量低约束样本下明显优于纯神经 WM，且打乱置信度后性能下降，则说明置信度引导的高置信塑形对低约束泛化具有实际价值。

7.4 学生限制候选

学生限制的目标是防止神经 WM 依靠训练集细节记忆、字段 shortcut 或过高模型容量直接拟合观测结果，而是促使其学习能够从高置信世界迁移到低约束世界的时序观测动态。这里的“限制”不一定表现为显式 bottleneck loss，也可以通过结构容量、输入扰动、训练采样和验证机制共同实现。第一版建议优先采用结构性限制和数据扰动，显式信息瓶颈损失仅作为后续候选。

1. Teacher 信息隔离 CPCG-WM 的主版本中，经典教师 p_c 和置信度 c 不应作为神经 WM 前向预测的常规输入。神经 WM 的前向输入应主要为：

$$O_{\leq t}, \quad a_{t:t+\tau-1}. \quad (34)$$

表 6: 约束渐进训练阶段参考

阶段	主要目标	候选操作
阶段 0	训练置信度模块, 校准经典教师可靠性	生成 p_c , 计算 e_c, c^* , 独立训练 Q_η
阶段 1	在高置信区域塑造稳定观测动态	高置信采样、强经典 KL、短 horizon、低 teacher dropout
阶段 2	从高置信过渡到中低置信区域	置信度分层采样、 $\lambda(c)$ 调制、多步预测、字段 masking
阶段 3	学习低约束新增自由度	加大低置信样本比例、弱经典约束、高置信 replay、reset optimizer
阶段 4	循环 refinement, 缓解遗忘和分布偏移	高置信 replay、混合训练、低约束适配交替进行
阶段 5	验证低约束少样本适配能力	少量低约束样本训练, 对照纯神经 WM 与打乱置信度版本

经典教师只通过训练损失影响模型:

$$\lambda(c)D_{\text{KL}}(p_c\|q_\theta). \quad (35)$$

这样可以避免模型在训练时直接读取经典教师输出并形成 shortcut。若后续需要比较, 可将 p_c 或 c 作为输入的版本作为消融实验, 而不作为主方法。

2. Latent 维度与模型容量控制 RSSM 的 latent state 维度、确定性 hidden state 维度、Transformer/RNN 层数和预测头规模都应作为容量控制对象。若模型容量过大, 可能在 IID 验证集上表现良好, 但在低约束组合或 leave-one-family-out 测试中失败。候选容量配置可分为:

1. 小容量 student: 用于验证经典一致性和高置信塑形是否能够提升紧凑模型的泛化;
2. 中等容量 student: 作为主实验配置;
3. 大容量 student: 作为上界对照, 用于观察是否出现记忆化风险。

容量控制的目标不是让模型过小, 而是避免模型在不学习可迁移动态规律的情况下完成训练集拟合。

3. 观测字段 dropout 与 masking 训练时随机遮蔽部分观测字段或历史片段, 可以降低模型对单一字段或固定日志格式的依赖:

$$\tilde{o}_t = M_t \odot o_t, \quad (36)$$

其中 M_t 为随机 mask。候选方式包括：

1. 字段级 dropout：随机遮蔽部分状态摘要字段；
2. 时间窗口 masking：随机缩短或遮蔽历史窗口中的若干时间步；
3. 事件 token dropout：随机丢弃部分高频事件 token；
4. 非关键字段扰动：对不稳定或噪声较大的测量字段加入轻微扰动。

该策略用于逼迫模型利用多字段、多时间步的稳定关联，而不是依赖某个字段的偶然相关性。

4. 历史窗口扰动与 horizon 随机化 若训练时总是使用固定长度历史窗口和固定预测步长，模型可能学习到数据生成格式本身，而不是通信动态规律。建议随机化历史窗口长度和预测 horizon：

$$L \sim \mathcal{U}(L_{\min}, L_{\max}), \quad \tau \sim \mathcal{H}. \quad (37)$$

历史窗口扰动可以提高模型对不同观测密度和不同决策频率的适应性；horizon 随机化可以防止模型只优化短期预测，而忽略长期动态稳定性。

5. 数据增强与噪声扰动 对于连续观测字段，可加入小幅噪声或量化扰动；对于离散 token，可进行低概率 token dropout 或 token replacement。该策略应谨慎使用，不应破坏动作-后果关系。适合扰动的字段包括测量噪声较大的 channel/link quality、contention proxy、traffic load summary 等；不适合随意扰动的字段包括动作 a_t 、真实事件顺序和关键协议状态。

6. 置信度分层验证与 leave-one-family-out 早停 学生限制不能只依赖训练 loss 判断。建议将 leave-one-family-out 和置信度分层误差作为模型选择与早停依据。若某个模型在 IID 验证集表现最好，但在未见 family 或低置信少样本适配中表现较差，则说明它可能发生记忆化。模型选择应综合：

1. 全量验证集多步观测 NLL；
2. 高、中、低置信分层误差；
3. leave-one-family-out 误差；
4. 低约束少样本适配速度；
5. 多步 rollout 稳定性。

7. 可选信息瓶颈损失 若结构性限制和数据扰动不足以抑制记忆化，可尝试显式信息瓶颈。建议采用容量受控的 KL 形式，而不是简单压缩 latent 到零：

$$\mathcal{L}_{IB} = |D_{\text{KL}}(q_{\theta}(z_t|o_{\leq t}) \| p(z_t)) - C_{IB}(t)|. \quad (38)$$

其中 $C_{IB}(t)$ 为随训练逐步增加的 latent 容量。该项的含义是限制模型每个时间步可携带的信息量，使其优先保留对未来观测预测有用的稳定因素。风险在于：若 C_{IB} 过小，模型可能丢失必要状态信息；若 KL 权重过大，可能导致 posterior collapse。因此该项仅作为候选，不建议第一版默认加入。

8. 动作反事实 batch 构造 为了确保 WM 学到动作条件动态，而不是仅根据历史观测外推未来，可构造同一或相近历史观测下的多动作 batch：

$$\{(o_{\leq t}, a_t^{(1)}, o_{t+\tau}^{(1)}), (o_{\leq t}, a_t^{(2)}, o_{t+\tau}^{(2)}), \dots\}. \quad (39)$$

该策略不一定需要额外 loss，但可以通过 batch 结构迫使模型区分不同动作导致的未来观测差异。若仿真器能够对同一初始状态运行多个候选动作，该策略会显著增强世界模型的 action-conditioned prediction 能力。

表 7: 学生限制候选策略

候选策略	作用	推荐程度
Teacher 信息隔离	防止 WM 直接读取 p_c 或 c 形成 short-cut，保证经典模型只通过 loss 塑形	第一版建议采用
模型容量控制	限制过强 student 记忆训练集，观察高置信塑形对紧凑模型的泛化作用	第一版建议采用
字段 dropout / masking	防止模型依赖单一字段或固定日志格式，提高观测动态鲁棒性	第一版建议采用
历史窗口与 horizon 随机化	提高模型对不同观测窗口和预测步长的适应性	第一版建议采用
数据增强与噪声扰动	降低对测量噪声和偶然相关性的记忆	谨慎采用
Leave-one-family-out 早停	用未见约束族泛化能力约束模型选择	强烈建议采用
信息瓶颈损失	显式限制 latent 信息量，逼迫模型学习紧凑预测因子	后续候选
动作反事实 batch	强化动作条件预测能力，避免模型仅做历史外推	若仿真成本允许，建议采用

9. 学生限制候选汇总

7.5 训练稳定化候选

以下策略按功能记录为候选，后续根据数据规模、字段质量和训练稳定性选择：

表 8: 训练稳定化候选策略

功能	候选策略
防止经典约束过强	$\lambda(c)$ warm-up、KL free bits、经典一致性 loss 上限裁剪。
防止学生过拟合	学生容量控制、字段 dropout、观测 masking、历史窗口扰动。
防止遗忘高置信规律	高置信样本 replay、分层采样、阶段性混入高置信 batch。
提高低约束适配	高置信预训练后加入中低置信样本，低置信少量适配。
防止 teacher 依赖	teacher dropout，即部分 batch 不使用经典一致性 KL。
优化器稳定	阶段切换时 reset optimizer；必要时只 reset prediction head。
多步预测稳定	从短 horizon 开始，逐步增加 τ ；或直接多 horizon 训练并调节 horizon 权重。

7.6 约束渐进训练候选流程

1. **高置信塑形阶段：** 优先采样高置信样本，使 WM 在经典可靠区域学习稳定观测动态。
2. **混合约束阶段：** 混合高、中、低置信样本，使用 $\lambda(c)$ 平滑调制经典一致性。
3. **低约束适配阶段：** 加大低置信和低约束样本比例，主要由真实观测 NLL 主导。
4. **高置信回放阶段：** 在低约束适配过程中持续少量回放高置信样本，防止遗忘高约束规律。

7.7 学生限制候选

学生限制的目标是避免 WM 记忆训练分布，而是优先学习可迁移观测动态。候选包括：

- 控制 latent 维度与模型容量；
 - 随机遮蔽部分观测字段或历史窗口；
 - 对非关键字段添加噪声扰动；
 - 使用较小 student 与较强数据增强；
 - 使用 leave-one-family-out 作为训练时验证信号，避免只优化 IID 分布误差。
- 这些策略不作为核心 loss，而作为训练工程候选。

8 实验设计与验证指标

8.1 核心对照组

表 9: 核心实验对照组

对照组	目的
纯神经 WM	检验没有经典一致性约束时的预测能力。
仅经典模型	检验经典模型本身在不同约束区域的表现。
固定 λ 经典一致性	检验置信度调制是否优于固定强度教师约束。
置信度调制经典一致性	主方法。
打乱置信度 c	检验置信度与样本可靠性的对应关系是否重要。
无高置信 warm-up	检验高置信塑形阶段的必要性。
无高置信 replay	检验低约束适配过程中是否发生高约束规律遗忘。

8.2 WM 预测指标，仅供参考

- 由于目标是观测级世界模型，评估不应仅包含 KPI。建议指标包括：
- 多步观测负对数似然： $NLL(o_{t+\tau})$ ；
 - 关键观测字段分布误差：CE/KL/Calibration；
 - 事件级预测准确率或 F1；
 - 状态摘要字段预测误差；
 - 多步 rollout 稳定性；

- 不同 horizon 下的误差增长曲线；
- 观测分布校准误差，例如 ECE、reliability diagram。

8.3 约束渐进泛化验证

1. **低约束少样本适配：**在低约束数据较少时，比较主方法与纯神经 WM 的收敛速度和最终误差。
2. **Leave-One-Family-Out：**留出一种约束自由度或自由度组合，测试模型是否泛化到未见组合。
3. **置信度分层评估：**分别统计高、中、低置信样本上的预测误差与经典一致性效果。
4. **置信度打乱实验：**打乱 c 后若性能下降，说明置信度调制确实提供有效训练信号。
5. **低约束新增自由度实验：**在经典模型低置信但高约束规律仍有迁移价值的场景中，测试少量低约束训练后的预测能力。

8.4 置信度模块评估

置信度模块独立评估指标包括：

- 预测置信度与经典模型真实误差的相关性；
- 高置信样本中经典模型误差分布；
- 低置信样本中经典模型误差分布；
- 可靠性曲线与 ECE；
- 多经典模型一致性、敏感性与小型校准网络之间的对比。

9 风险与应对

表 10: 主要风险与应对策略

风险	表现	应对
经典模型覆盖子空间过窄	经典 KL 只覆盖少量观测字段, 训练影响弱。	扩展经典教师字段; 使用状态摘要字段; 提高高置信样本比例。
置信度估计不稳	高置信样本中经典误差仍大。	引入真实误差校准、多模型一致性、敏感性特征。

经典一致性过强	WM 被错误经典模型限制。	调整 $\lambda(c)$ 、增加 loss clipping、降低高置信阈值。
神经 WM 过拟合	IID 验证好, OOD/低约束差。	增加学生限制、leave-one-family-out、observation masking。
数据字段不足	难以构造完整 o_t 。	先使用状态摘要 token 与关键事件 token, 逐步扩展。
仿真成本高	大规模 episode 生成慢。	分阶段生成; 先轻量场景, 再 Kom8ndor 重点验证。

10 预期贡献

1. 提出**约束渐进式置信度引导 WM**, 将经典通信模型从前向残差或模型模块转化为训练时置信度加权软教师。
2. 构建面向通信系统的观测级时序世界模型训练框架, 目标为 $q_\theta(o_{t+\tau}|o_{\leq t}, a_t)$ 。
3. 建立经典模型置信度估计、 $\lambda(c)$ 调制机制以及一些候选技巧, 使高约束规律塑形与低约束自由度学习在统一 loss 中平滑衔接。
4. 基于 ns-3、Komondor/Kom8ndor 生成约束渐进通信轨迹数据, 形成可复现实验流程。
5. 提供面向低约束少样本适配、置信度消融和 leave-one-family-out 的系统评估方案。

11 总结

CPCG-WM 的核心是: 世界模型直接学习未来观测序列分布, 经典模型不参与前向残差, 而是在训练阶段通过置信度加权经典一致性损失约束神经模型。高置信样本用于塑造经典可靠区域的观测动态, 低置信样本由真实观测数据主导, 以学习低约束世界中的新增自由度。RSSM 风格 latent dynamics、多步观测预测、NLL/KL 训练、置信度模块分开训练、约束渐进数据族和系统消融实验共同构成该研究的可实施路线。

参考文献

- [1] F. Wilhelmi, S. Barrachina-Muñoz, and B. Bellalta, “Kom8ndor: An IEEE 802.11bn-Oriented Simulator for Wi-Fi 8 and Beyond,” *arXiv preprint arXiv:2606.25435*, 2026.

- [2] F. Wilhelmi, B. Bellalta, G. Geraci, L. Galati-Giordano, F. Meneghello, A. Kijanka, I. Val, and D. López-Pérez, “A Tutorial on IEEE 802.11bn Multi-AP Coordination for Wi-Fi 8: From Standardization to Performance Evaluation,” *arXiv preprint arXiv:2606.13759*, 2026.
- [3] D. Hafner, J. Pasukonis, J. Ba, and T. Lillicrap, “Mastering Diverse Domains through World Models,” *arXiv preprint arXiv:2301.04104*, 2023.
- [4] N. Hansen, H. Su, and X. Wang, “TD-MPC2: Scalable, Robust World Models for Continuous Control,” *arXiv preprint arXiv:2310.16828*, 2023.
- [5] M. Burchi and R. Timofte, “MuDreamer: Learning Predictive World Models without Reconstruction,” *arXiv preprint arXiv:2405.15083*, 2024.

.....